

Fase 1: Planteamiento - Aprendizaje Profundo

Selección de la Problemática

Debido a la importancia del sector agrónomo en México para su economía, yo considero aplicar inteligencia artificial en una problemática con alto impacto en los agronegocios. Esta problemática es una clasificación multiclase de frijoles secos. En la actualidad se hace una inspección visual para clasificar frijoles secos en sus diferentes categorías. Para optimizar este proceso, se puede utilizar Aprendizaje Profundo para clasificarlos.

En mi propuesta del proyecto, se debe clasificar automáticamente la variedad de un frijol seco a partir de medidas geométricas obtenidas de su imagen. Como mencionado anteriormente, esta problemática es adecuada para un problema de Aprendizaje Profundo, porque se debe de hacer una clasificación multiclase debido a que mis datos experimentales contienen 7 clases de frijoles secos y que muchas de estas características comparten similitudes. Este conjunto de datos que conseguí de Kaggle tiene 13,611 muestras con 16 características con una clase ya definida. Además, este dataset permite explorar el desbalance de clases y clases confundibles, lo cual agrega un nivel de dificultad superior que permite utilizar diferentes técnicas de manipulación de los datos, entrenamiento del modelo y análisis cuantitativo.

Recopilación y Clasificación de Datos

Los datos fueron obtenidos de Kaggle: <https://www.kaggle.com/datasets/sansuthi/dry-bean-dataset>. Para obtener estos datos, se tomaron fotos de 13,611 granos de frijoles secos con una cámara de alta resolución. Estas imágenes pasaron por un sistema de visión por computadora, el cual segmenta la imagen y extrae 16 características de cada muestra de frijol seco.


Este tipo de datos son estructurados y tabulares, porque cada fila es una muestra de frijol. Cada columna representa conceptualmente una característica de una muestra. A nivel de código, cada columna sería considerada como una variable de entrada "x". Las 16 variables de entrada son numéricas continuas. En este conjunto de datos, la variable de salida "y" representa la categoría del frijol. Esta variable de salida es categórica nominal. Se necesita utilizar aprendizaje supervisado con clasificación multiclase en este tipo de problemas, puesto que las muestras tienen etiqueta conocida y el objetivo es predecir la categoría de la muestra de frijol dentro de las 7 categorías mutuamente excluyentes.

Entrada/Salida	Variable	Descripción	Tipo
Entrada	Area	El área del frijol y el número de píxeles dentro de sus límites.	Numérica Continua
Entrada	Perimeter	La circunferencia del frijol es definida como el largo de su borde.	Numérica Continua
Entrada	MajorAxisLength	La distancia entre los extremos de la línea más larga que puede ser dibujada en un frijol	Numérica Continua
Entrada	MinorAxisLength	La línea perpendicular más larga que puede ser dibujada en el frijol en el eje principal.	Numérica Continua
Entrada	AspectRatio	Define la relación entre L y l.	Numérica Continua
Entrada	Eccentricity	La excentricidad de la elipse que tiene los mismos momentos que la región.	Numérica Continua
Entrada	ConvexArea	Número de píxeles del polígono convexo más pequeño que puede contener el área de la semilla de frijol.	Numérica Continua
Entrada	EquivDiameter	El diámetro de un círculo que tiene la misma área que una semilla de frijol.	Numérica Continua
Entrada	Extent	La proporción entre los píxeles de la caja delimitadora y el área del frijol.	Numérica Continua
Entrada	Solidity	También conocida como convexidad. Es la proporción de	Numérica Continua

		píxeles en la envolvente convexa y los que se encuentran en los frijoles.	
Entrada	roundness	Se calcula con la siguiente fórmula: $(4\pi A)/P^2$	Numérica Continua
Entrada	Compactness	Mide que tan redondo es un objeto E_d/L	Numérica Continua
Entrada	ShapeFactor1	Factor de forma no especificado en la documentación	Numérica Continua
Entrada	ShapeFactor2	Factor de forma no especificado en la documentación	Numérica Continua
Entrada	ShapeFactor3	Factor de forma no especificado en la documentación	Numérica Continua
Entrada	ShapeFactor4	Factor de forma no especificado en la documentación	Numérica Continua
Salida	Class	Tipo de frijol	Categórica Nominal

El conjunto contiene 13,611 muestras, esta es la siguiente distribución de los valores:

Clase	Muestra	Porcentaje
Dermason	3,546	26.1 %
Sira	2,636	19.4 %
Seker	2,027	14.9 %
Horoz	1,928	14.2 %
Cali	1,630	12.0 %
Barbunya	1,322	9.7 %
Bombay	522	3.8 %
Total	13,611	100 %



Definición del Tipo de Información Relevante

Las propiedades del frijol son diferentes según sus variedades. Estas propiedades son las variables de entrada numéricas continuas. La variable de salida (clase) es la siguiente: Dermason, Sira, Seker, Horoz, Cali, Barbunya y Bombay. La clase de frijol es categórica y nominal.

Explorando los datos de Kaggle, me di cuenta que hay variedades de los frijoles que tienen medidas similares entre sí en sus características. Para evitar que se clasifiquen los frijoles de forma errónea, se necesita utilizar diferentes medidas geométricas de cada muestra. Por ende, la red neuronal tiene que combinar varias variables para encontrar patrones que una regla manual no puede encontrar. Además, al ser medidas con escalas distintas, se tiene que normalizar los valores antes del entrenamiento.

Método de Solución

Para este tipo de datos, voy a utilizar el perceptrón multicapa (MLP) con una red feedforward para clasificación multiclase. Esta decisión es tomada basándome en lo que hemos aprendido en clase y las actividades anteriores en las cuales analizamos el conjunto de datos de Iris para hacer una clasificación multiclase. A comparación de CNN (utilizada para estructuras espaciales como píxeles) y RNN (utilizada para series de tiempo), utilizar un MLP sería lo ideal, porque los datos son tabulares y numéricos. Con el MLP se puede aprender combinaciones no lineales entre las características. Finalmente, se puede comparar con otras arquitecturas en fases posteriores del proyecto si los resultados no son suficientes.

Análisis de la Red Neuronal Artificial

Mi arquitectura inicial para la red neuronal va a tener tres capas: una de entrada, una oculta y una de salida. La capa oculta va a tener una función de activación ReLU por ser estándar para redes densas. Mi arquitectura se va a probar en fases posteriores con variantes y con otras funciones de activación en dado caso que no se obtenga el resultado deseado, aunque las capas de entrada y salida no van a cambiar debido a que dependen del conjunto de datos.

Capa	Neuronas	Función	Activación
Entrada	16	Una neurona por cada característica (variable normalizada)	No aplica
Oculto	64	Aprende combinaciones no lineales de forma y tamaño	ReLU
Salida	7	Una neurona de salida por cada clase de frijol	Softmax

Como mencionado previamente, el número de neuronas en la capa oculta es una propuesta inicial. En fases posteriores, la cantidad de neuronas en la capa oculta puede ser ajustada o se agregaría otra capa oculta. La capa oculta tiene mucha importancia en un MLP, porque es utilizada para aprender relaciones no lineales entre las variables.

El motivo por el cual opté implementar ReLU en mi capa oculta es porque devuelve 0 si el valor de entrada es negativo y el mismo valor de entrada si el valor es positivo resultando en un entrenamiento eficiente. Adicionalmente, ReLU evita el gradiente que se desvanece, porque no se satura en la parte positiva. En contraste, las funciones de activación Sigmoide y Tanh se saturan con valores grandes y el aprendizaje se frena. Finalmente, ReLU aporta la no linealidad necesaria como mencionado en el párrafo anterior. Sin una función de activación, la capa oculta equivaldría a una operación lineal. Por consiguiente, la red no podría separar clases que tengan límites que no son rectos.

La capa de salida tiene 7 neuronas con la función de activación Softmax. Según lo aprendido en clase, se debe de utilizar Softmax para problemas de clasificación multiclase. Además, debe de haber una neurona por cada clase de frijol. Con la función de activación Softmax, se obtiene como resultado una probabilidad de que la muestra pertenezca a cada variedad de frijol. Finalmente, voy a utilizar entropía cruzada categórica como función de pérdida, porque esta es la función de pérdida análoga a la de entropía cruzada binaria (aprendida en clase) cuando hay tres o más clases.

Conclusión

Me interesó trabajar con este conjunto de datos, porque he trabajado en proyectos que involucren recolección de datos por medio de fotografías. A mi percepción, esta es un área de oportunidad para poder mejorar los negocios, debido a que es muy costoso y lento emplear a gente que solamente se dedique a inspeccionar artículos de forma visual. Asimismo, en las inspecciones manuales es muy común que se introduzcan errores humanos.

Si es necesario, en las siguientes fases me gustaría probar y mejorar la arquitectura de mi red neuronal propuesta. Puedo hacerle modificaciones como agregar capas ocultas y cambiar la cantidad de neuronas en las capas ocultas. Las capas de entrada y salida no pueden ser modificadas, porque estas dependen directamente de la cantidad de características y la cantidad de clases.

Al hacer exploración de datos, encontré que algunas clases tienen más muestras que las demás resultando en un desbalance de clases. Un efecto secundario del desbalance de clases es que el modelo puede favorecer a las clases con mayor cantidad de muestras y el desempeño (accuracy) del modelo puede ocultarlo. Adicionalmente, algunas clases son confundibles, porque algunas variedades de frijol seco tienen formas parecidas. Por ejemplo, en el conjunto de datos existen variables correlacionadas como *Area*, *Perimetro*, *EquivDiameter* y *ConvexArea* que aportan información muy similar. Finalmente, todas las muestras provienen de la misma cámara y utilizan el mismo sistema de visión por computadora. Como resultado, existe la posibilidad de que el modelo no generalice de forma óptima con datos extraídos de otra cámara que tenga variaciones en las siguientes variables: iluminación y sombras en los objetos, resolución de píxeles o ángulo del lente.

Uno de los motivos por el cual decidí utilizar este conjunto de datos es porque en el tetramestre anterior (Aprendizaje Automático), aprendí que un desbalance de clases puede tener una influencia en los resultados de las pruebas. En este tipo de situaciones, se necesita entrenar cuidadosamente la red neuronal y diseñar de forma correcta con la finalidad de que no afecte en los resultados y, como consiguiente, que no sean ignoradas las clases con menor cantidad de muestras como consecuencia de un sesgo generado en el entrenamiento. Por ejemplo, se pueden aplicar pesos por clase (ponderación por clase) o sobremuestreo solo en el conjunto de entrenamiento para que las clases con menor cantidad de muestras tengan mayor importancia en el aprendizaje. Además, los datos se dividen de forma estratificada, con lo que se mantiene la proporción de cada clase en entrenamiento y prueba.

Tomando en cuenta el desbalance de clases, el modelo puede tener mejor accuracy en las clases grandes y tener malos resultados en las clases pequeñas. Como consecuencia, se puede tener un accuracy alto para el modelo, aunque clasifique de forma equivocada las clases. Con este conjunto de datos, el utilizar únicamente accuracy para evaluar el modelo puede derivar en la obtención de un modelo sesgado. Por estos motivos, considero que una matriz de confusión proporciona un análisis más completo de las predicciones. Asimismo, las métricas de precisión, recall y F1 por clase serán útiles por los siguientes motivos:

- Precision: Proporción de frijoles correctamente clasificados entre todos los que el modelo etiquetó como una variedad. Mide la confiabilidad del modelo cuando predice esa clase.
- Recall: Proporción de frijoles de una variedad que el modelo logró identificar entre todos los que realmente pertenecen a ella. Un recall bajo indica que muchos frijoles de esa variedad se están clasificando como otra clase.
- F1: Es la media armónica de precision y recall. Solamente tiene un valor alto cuando ambas métricas lo son. Resume el desempeño por clase en un solo valor.